Introducere in *NumPy* si *Matplotlib*

Teorie

1. Numpy

- cea mai utilizata biblioteca Python pentru calculul matematic
- dispune de obiecte multidimensionale (vectori, matrici) si functii optimizate sa lucreze cu acestea

Importarea bibliotecii:

```
import numpy as np
```

Vectori multidimensionali:

- initializati folosind o lista din *Python*

```
a = np.array([1, 2, 3])
print(a)            # => [1 2 3]
print(type(a))      # tipul obiectului a => <class 'numpy.ndarray'>
print(a.dtype)      # tipul elementelor din a => int32
print(a.shape)      # tuple continand lungimea lui a pe fiecare dimensiune => (3,)
print(a[0])         # acceseaza elementul avand indexul 0 => 1

b = np.array([[1, 2, 3], [4, 5, 6]])
print(b.shape)      # => (2, 3)
print(b[0][2])      # => 3
print(b[0, 2])      # => 3

c = np.asarray([[1, 2], [3, 4]])
print(type(c))      # => <class 'numpy.ndarray'>
print(c.shape)      # => (2, 2)
```

- creati folosind functii din *NumPy*

```
zero_array = np.zeros((3, 2))           # creeaza un vector continand numai 0
print(zero_array)                       # => [[0. 0.]
                                        #     [0. 0.]
                                        #     [0. 0.]]

ones_array = np.ones((2, 2))           # creeaza un vector continand numai 1
print(ones_array)                       # => [[0. 0.]
                                        #     [0. 0.]]


constant_array = np.full((2, 2), 8)     # creeaza un vector constanta
print(constant_array)                   # => [[8 8]
                                        #     [8 8]]
```

```
identity_matrix = np.eye(3)        # creeaza matricea identitate de dimensiune 3x3
print(identity_matrix)             # => [[1. 0. 0.]
                                   #     [0. 1. 0.]
                                   #     [0. 0. 1.]]

random_array = np.random.random((1,2))  # creeaza un vector cu valori aleatoare
print(random_array)                     # => ex: [[0.00672748 0.12277961]]

mu, sigma = 0, 0.1
gaussian_random = np.random.normal(mu, sigma, 10)  # creeaza un vector cu valori
                                                   # random cu distributie
                                                   # Gaussiana de medie mu si
                                                   # deviatie standard sigma

first_5 = np.arange(5)     # creeaza un vector continand primele 5 numere naturale
print(first_5)             # => [0 1 2 3 4]
```

Indexare:

Slicing: extragerea unei submultimi - trebuie specificati indecsii doriti pe fiecare dimensiune

```
array_to_slice = np.array([[1,2,3,4], [5,6,7,8], [9,10,11,12]])
slice = array_to_slice[:, 0:3]      # luam toate liniile si coloanele 0, 1, 2
print(slice)                        # => [[ 1  2  3]
                                    #     [ 5  6  7]
                                    #     [ 9 10 11]]

# !! modificarea slice duce automat la modificarea array_to_slice
print(array_to_slice[0][0])         # => 1
slice[0][0] = 100
print(array_to_slice[0][0])         # => 100

# pentru a nu se intampla acest lucru submultimea poate fi copiata
slice_copy = np.copy(array_to_slice[:, 0:3])
slice_copy[0][0] = 100
print(slice_copy[0][0])        # => 100
print(array_to_slice[0][0])    # => 1
```

In cazul in care unul din indecsi este un intreg, dimensiunea submultimii returnate este mai mica decat dimensiunea initiala:

```
slice_1 = array_to_slice[2:3, :]
print(slice_1)                      # => [[ 9 10 11 12]]
slice_2 = array_to_slice[2, :]
print(slice_2)                      # => [ 9 10 11 12]

# returnarea tuturor elementelor intr-un array 1D:
slice_1d = np.ravel(slice_1)
print(slice_1d)                   # => [ 9 10 11 12]
```

```
# dimensiunea vectorilor poate fi modificata folosind functia np.reshape
reshaped_array = np.reshape(array_to_slice, (2, 6))
print(reshaped_array)           # => [[ 1  2  3  4  5  6]
                                #     [ 7  8  9 10 11 12]]
```

Folosind vectori de intregi:

```
print(array_to_slice[[0,0], [1,3]])  # afiseaza elementele de pe pozitiile
                                     # [0,1] si [0,3] => [2 4]
```

Folosind vectori de valori bool:

```
# Vrem sa afisam toate elementele mai mari decat 10 din array_to_slice
bool_idx = (array_to_slice > 10)  # rezulta o matrice de aceeasi dimensiune cu
                                  # array_to_slice in care fiecare element consta
                                  # intr-o valoare bool astfel:
                                  # True, daca elementul corespunzatoe din
                                  #       array_to_slice > 10
                                  # False, daca elementul corespunzatoe din
                                  #       array_to_slice <= 10

print(bool_idx)     # => [[ True False False False]
                    #     [False False False False]
                    #     [False False  True  True]]

print(array_to_slice[bool_idx])  # => [100  11  12]

# Operatia se poate face si direct:
print(array_to_slice[array_to_slice > 10])     # => [100  11  12]
```

Functii matematice:

Operatiile matematice de baza sunt disponibile atat ca functii NumPy cat si ca operatori si sunt aplicate element cu element:

```
x = np.array([[1,2],[3,4]], dtype=np.float64)
y = np.array([[5,6],[7,8]], dtype=np.float64)

# Suma element cu element => [[ 6.0  8.0]
#                            [ 10.0 12.0]]
print(x + y)
print(np.add(x, y))

# Diferenta element cu element => [[ -4.0 -4.0]
#                                  [-4.0 -4.0]]
print(x - y)
print(np.subtract(x, y))

# Produs element cu element => [[ 5.0  12.0]
#                               [ 21.0 32.0]]
print(x * y)
```

```
print(np.multiply(x, y))

# Impartire element cu element => [[ 0.2        0.33333333]
#                                  [ 0.42857143 0.5]]
print(x / y)
print(np.divide(x, y))

# Radical element cu element => [[ 1.          1.41421356]
#                                [ 1.73205081  2.]]
print(np.sqrt(x))

# Ridicare la putere
my_array = np.arange(5)
powered = np.power(my_array, 3)
print(powered)                      # => [ 0  1  8 27 64]
```

Produsul scalar:

```
x = np.array([[1,2],[3,4]])
y = np.array([[5,6],[7,8]])

v = np.array([9,10])
w = np.array([11, 12])

# vector x vector => 219
print(v.dot(w))
print(np.dot(v, w))

# matrice x vector => [29 67]
print(np.matmul(x, v))

# matrice x matrice => [[19 22]
#                       [43 50]]
print(np.matmul(x, y))
```

Operatii pe matrici:

```
# transpusa unei matrici
my_array = np.array([[1, 2, 3], [4, 5, 6]])    # [[1, 2, 3],
                                               #  [4, 5, 6]]
print(my_array.T)            # => [[1, 4],
                             #     [2, 5],
                             #     [3, 6]]
# inversa unei matrici
my_array = np.array([[1., 2.], [3., 4.]])
print(np.linalg.inv(my_array))          # => [[-2. ,  1. ],
                                        #     [ 1.5, -0.5]]
```

NumPy dispune de functii care fac operatii pe o anumita dimensiune.

```
x = np.array([[1, 2],[3, 4]])

# suma pe o anumita dimensiune
print(np.sum(x))                # Suma tuturor elementelor => 10
print(np.sum(x, axis=0))        # Suma pe coloane => [4 6]
print(np.sum(x, axis=1))        # Suma pe linii => [3 7]
# putem specifica si mai multe axe pe care sa se faca operatia:
print(np.sum(x, axis=(0,1)))    # Suma tuturor elementelor => 10


# media pe o anumita dimensiune
y = np.array([[[1, 2, 3, 4], [5, 6, 7, 8]], [[1, 2, 3, 4], [5, 6, 7, 8]], [[1, 2, 3,
4], [5, 6, 7, 8]]])
print(y.shape)      # => (3, 2, 4)
print(y)            # => [[[1 2 3 4]
                    #      [5 6 7 8]]
                    #     [[1 2 3 4]
                    #      [5 6 7 8]]
                    #     [[1 2 3 4]
                    #      [5 6 7 8]]]

print(np.mean(y, axis=0))       # => [[1. 2. 3. 4.]
                                #     [5. 6. 7. 8.]]

print(np.mean(y, axis=1))       # => [[3. 4. 5. 6.]
                                #     [3. 4. 5. 6.]
                                #     [3. 4. 5. 6.]]

# indexul elementului maxim pe fiecare linie
z = np.array([[10, 12, 5],[17, 11 ,19]])
print(np.argmax(z, axis=1))    # => [1 2]
```

Broadcasting:

- mecanism care ofera posibilitatea de a face operatii aritmetice intre vectori de dimensiuni diferite
- vectorul mai mic este multipilcat astfel incat sa se potriveasca cu cel mai mare, operatia fiind apoi realizata pe cel din urma

```
# Vrem sa adaugam un vector (v) la fiecare linie a unei matrici (x)
x = np.array([[1,2,3], [4,5,6], [7,8,9], [10, 11, 12]])
v = np.array([1, 0, 1])
y = x + v
print(y)  # => [[ 2  2  4]
          #     [ 5  5  7]
          #     [ 8  8 10]
          #     [11 11 13]]
```

Reguli de broadcasting:

1. Daca vectorii nu au acelasi numar de dimensiuni, vectorul mai mic este extins cu cate o dimensiune, pana cand acest lucru este realizat.
   ex: Daca avem 2 vectori ***a*** si ***b*** cu
   a.shape = (3, 4)
   b.shape = (6,)
   b este extins la dimensiunea (6, 1)

2. Cei 2 vectori se numesc compatibili pe o dimensiune daca au aceeasi lungime pe acea dimensiune sau daca unul dintre ei are lungimea 1.
   ex: Consideram vectorii:
   a astfel incat: a.shape = (3, 4)
   b astfel incat: b.shape = (6, 1)
   c astfel incat: c.shape = (3, 5)

   a si ***c*** sunt compatibili pe prima dimensiune
   a si ***b*** sunt compatibili pe cea de-a doua dimensiune

3. Pe cei 2 vectori se poate aplica broadcasting daca ei sunt compatibili pe toate dimensiunile.

4. La broadcasting fiecare vector se comporta ca si cum ar avea, pe fiecare dimensiune, lungimea maxima dintre cele doua dimensiuni initiale (maximul dimensiunilor elementwise)
   ex: La broadcasting vectorii ***a*** si ***b*** cu
   a.shape = (3, 4)
   b.shape = (3, 1)
   se comporta ca si cum ar avea dimensiunea (3, 4)

5. In fiecare dimensiune pe care unul din vectori avea dimensiunea 1, iar celalalt mai mare, primul vector se comporta ca si cum ar fi copiat de-a lungul acelei dimensiuni.
   ex: Consideram vectorii:
   a = [[1, 2, 3],
   [4, 5, 6]] , a.shape = (2, 3)

   b = [[1.],
   [1.]] , b.shape = (2, 1)

   Cand vrem sa facem o operatie de broadcasting, vectorul b va fi copiat de-a lungul celei de-a doua dimensiuni, astfel incat el devine:

b = [[1., 1., 1.],
[1., 1., 1.]] , b.shape = (2, 3)
operatia fiind acum realizata pe vectori de aceeasi dimensiune.

2. Matplotlib

- biblioteca utilizata pentru plotarea datelor

Importarea bibliotecii:

```
import matplotlib.pyplot as plt
```

Plotare:

- cea mai importanta functie este *plot*, care permite afisarea datelor 2D

```
# Calculeaza coordonatele (x, y) ale punctelor de pe o curba sin
# x - valori de la 0 la 3 * np.pi, luate din 0.1 in 0.1
x = np.arange(0, 3 * np.pi, 0.1)
y = np.sin(x)

# Ploteaza punctele
plt.plot(x, y)

# Adauga etichete pentru fiecare axa
plt.xlabel('x axis label')
plt.ylabel('y axis label')

# Adauga titlu
plt.title('Sine')

# Adauga legenda
plt.legend(['Sine'])

# Afiseaza figura
plt.show()
```

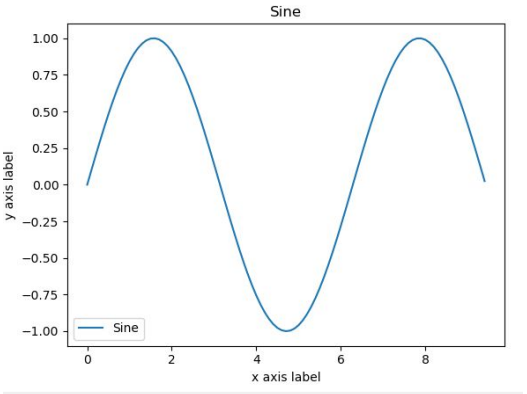

OBS. Pentru a plota punctele independent, fara a face interpolare ca in exemplul anterior, se poate specifica un al treilea parametru in functia plot, astfel:

```
plt.plot(x, y, 'o')
```

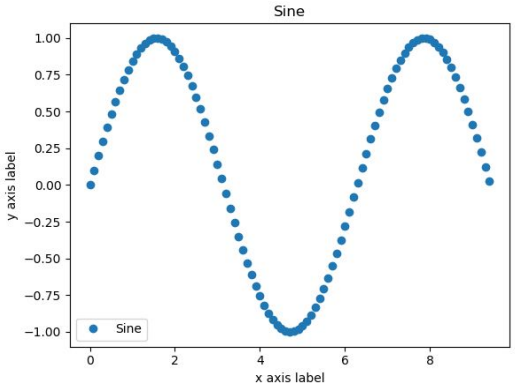

Plotarea mai multor grafice in cadrul aceleiasi figuri:

```
# Calculeaza coordonatele (x, y) ale punctelor de pe o curba sin, respectiv cos
# x - valori de la 0 la 3 * np.pi, luate din 0.1 in 0.1
x = np.arange(0, 3 * np.pi, 0.1)
y_1 = np.sin(x)
y_2 = np.cos(x)

# Ploteaza punctele in aceeasi figura
plt.plot(x, y_1)
plt.plot(x, y_2)

# Adauga titlu
plt.title('Sine and Cosine')

# Adauga legenda
plt.legend(['Sine', 'Cosine'])

# Afiseaza figura
plt.show()
```

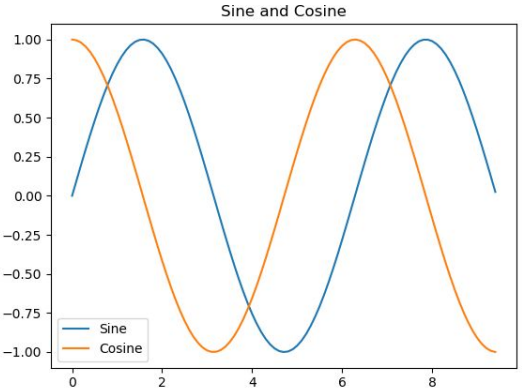

Plotarea simultana a mai multor grafice in figuri diferite:

```
# Calculeaza coordonatele (x, y) ale punctelor de pe o curba sin, respectiv cos
# x - valori de la 0 la 3 * np.pi, luate din 0.1 in 0.1
```

```
x = np.arange(0, 3 * np.pi, 0.1)
y_1 = np.sin(x)
y_2 = np.cos(x)

# definim primul plot in figura 1
first_plot = plt.figure(1)
plt.plot(x, y_1)
plt.title('Sine')
plt.legend(['Sine'])

# definim cel de-al doilea plot in figura 2
second_plot = plt.figure(2)
plt.plot(x, y_2)
plt.title('Cosine')
plt.legend(['Cosine'])

# afisam figurile
plt.show()
```

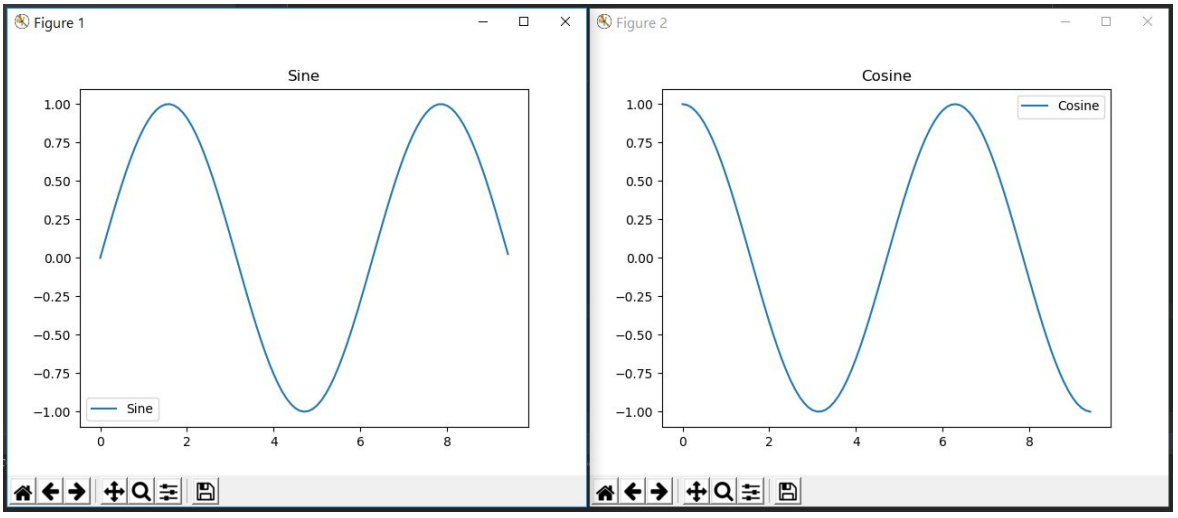

Sublotare:

- putem plota mai multe lucruri in cadrul aceleiasi figuri

```
# Calculeaza coordonatele (x, y) ale punctelor de pe o curba sin, respectiv cos
x = np.arange(0, 3 * np.pi, 0.1)
y_sin = np.sin(x)
y_cos = np.cos(x)

# Creeaza un grid avand inaltimea 2 si latimea 1
# si seteaza primul subplot ca activ
plt.subplot(2, 1, 1)

# Ploteaza primele valori
plt.plot(x, y_sin)
plt.title('Sine')
```

```
# Seteaza cel de-al doilea subplot ca activ
# si ploteaza al doilea set de date
plt.subplot(2, 1, 2)
plt.plot(x, y_cos)
plt.title('Cosine')

# Afiseaza figura
plt.show()
```

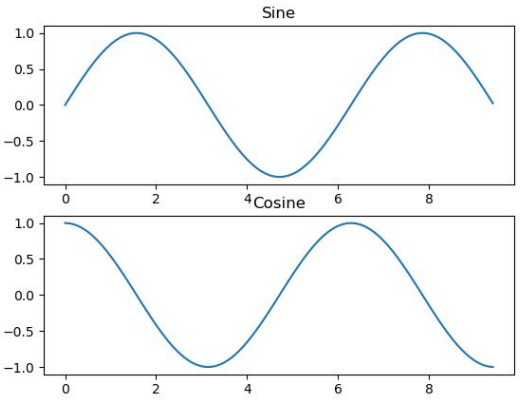

Exercitii

1. Se dau urmatoarele 9 imagini de dimensiuni 400x600. Valorile acestora au fost salvate in fisierele “images/car_{idx}.npy”.

   a. Cititi imaginile din aceste fisiere si salvati-le intr-un np.array (va avea dimensiunea 9x400x600).

      Obs: Cititrea din fisier se face cu ajutorul functiei:

```
image = np.load(file_path)
```

Aceasta intoarce un np.array de dimensiune 400x600.

b. Calculati suma valorilor pixelilor tuturor imaginilor.

c. Calculati suma valorilor pixelilor pentru fiecare imagine in parte.

d. Afisati indexul imaginii cu suma maxima.

e. Calculati imaginea medie si afisati-o.
Obs: Afisarea imaginii medii se poate face folosind biblioteca *scikit-image* in urmatorul mod:

```
from skimage import io
io.imshow(mean_image.astype(np.uint8)) # petru a putea fi afisata
                                       # imaginea trebuie sa aiba
                                       # tipul unsigned int
io.show()
```

Daca biblioteca nu este instalata, acest lucru se poate face prin rularea comenzii sistem `pip install scikit-image`.

f. Cu ajutorul functiei `np.std(images_array)`, calculati deviatia standard a imaginilor.
g. Normalizati imaginile. (se scade imaginea medie si se imparte rezultatul la deviatia standard)

h. Decupati fiecare imagine, afisand numai liniile cuprinse intre 200 si 300 si coloanele cuprinse intre 280 si 400.