


## Metoda celor mai apropiați vecini



Exemplu care arată diferențele dintre metoda celui mai apropiat vecin și metoda celor mai apropiați cinci vecini. Zona colorată reprezintă regiunea de decizie a clasificatorului folosind distanța L2. Se observă că în cazul metodei celui mai apropiat vecin se formează mici 'insule' ce pot duce la predicții incorecte. Zonele gri din imaginea 5-NN reprezintă zone de predicție ambigue din cauza egalității voturilor celor mai apropiați vecini.

În acest laborator vom clasifica cifrele scrise de mână din subsetul **MNIST** folosind metoda celor mai apropiați vecini.

**Descarcăți arhiva cu datele de antrenare și testare [de aici](#).**

? Care este acurătatea metodei celor mai apropiați vecini pe mulțimea de *antrenare* când se folosește numărul de vecini egal cu 1 și distanța L2? Dar pentru distanța L1?

? Care este acurătatea metodei celor mai apropiați vecini pe mulțimea de *antrenare* când se folosește numărul de vecini  $K \geq 2$  și distanța L2? Dar pentru distanța L1?

## Exerciții

1. Creați clasa `Knn_classifier`, având constructorul următor:

```
def __init__(self, train_images, train_labels):
    self.train_images = train_images
    self.train_labels = train_labels
```

2. Definiți metoda `classify_image(self, test_image, num_neighbors = 3, metric = 'l2')` care clasifică imaginea `test_image` cu metoda celor mai apropiați vecini, numărul vecinilor este stabilit de parametru `num_neighbors`, iar distanța poate fi L1 sau L2, în funcție de parametrul `metric`.

**Obs:**

- $L1(X, Y) = \sum_{i=1}^n |X_i - Y_i|$
- $L2(X, Y) = \sqrt{\sum_{i=1}^n (X_i - Y_i)^2}$
- În variabilele *train\_images* și *test\_image* valorile unui exemplu sunt stocate pe linie. (*train\_images.shape* = (num\_samples, num\_features), *test\_image.shape* = (1, num\_features) )

3. Calculați acuratetea metodei celor mai apropiați vecini pe mulțimea de testare având ca distanță 'l2' și numărul de vecini 3. Salvați predicțiile în fișierul *predictii\_3nn\_l2\_mnist.txt*.

**Obs:**

- Acuratetea pe mulțimea de testare este de 89.8%.

4. Definiți metoda *confusion\_matrix(y\_true, y\_pred)* care calculează matricea de confuzie. Calculați matricea de confuzie folosind predicțiile din *predictii\_3nn\_l2\_mnist.txt*.

**Obs:**

- Matrice de confuzie  $C = c_{ij}$ , numărul exemplurilor din clasa  $i$  care au fost clasificate ca fiind în clasa  $j$ .


Clasa actuală ↓ Clasa prezisă →	1	2	3
1	Nr. exemplurilor din clasa 1 care au fost clasificate ca fiind în clasa 1	Nr. exemplurilor din clasa 1 care au fost clasificate ca fiind în clasa 2	Nr. exemplurilor din clasa 1 care au fost clasificate ca fiind în clasa 3
2	Nr. exemplurilor din clasa 2 care au fost clasificate ca fiind în clasa 1	Nr. exemplurilor din clasa 2 care au fost clasificate ca fiind în clasa 2	Nr. exemplurilor din clasa 2 care au fost clasificate ca fiind în clasa 3
3	Nr. exemplurilor din clasa 3 care au fost clasificate ca fiind în clasa 1	Nr. exemplurilor din clasa 3 care au fost clasificate ca fiind în clasa 2	Nr. exemplurilor din clasa 3 care au fost clasificate ca fiind în clasa 3

- Matricea de confuzie pentru clasificatorul anterior este:


```
[[51.  0.  0.  0.  0.  1.  1.  0.  0.  0.]
 [ 0. 52.  0.  0.  0.  0.  0.  0.  0.  0.]
 [ 1.  6. 47.  1.  0.  0.  1.  2.  0.  0.]
 [ 0.  0.  0. 51.  0.  1.  0.  0.  0.  1.]
 [ 0.  0.  0.  0. 44.  0.  0.  0.  0.  2.]
 [ 2.  1.  1.  6.  0. 40.  1.  0.  0.  1.]
 [ 0.  0.  0.  0.  0.  1. 47.  0.  0.  0.]
 [ 1.  2.  0.  0.  1.  0.  0. 46.  0.  0.]
 [ 1.  0.  2.  2.  1.  1.  1.  1. 36.  1.]
 [ 0.  0.  1.  1.  3.  1.  0.  1.  0. 35.]]
```

5. Calculati acuratetea metodei celor mai apropiati vecini pe multimea de testare avand ca distanta L2 si numarul de vecini  $\in [1, 3, 5, 7, 9]$ .

- a. Plotati un grafic cu acuratetea obtinuta pentru fiecare vecin si salvati scorurile in fisierul *acuratete\_l2.txt*.



- b. Repetati punctul anterior pentru distanta L1. Plotati graficul de la punctul anterior in aceeaasi figura cu graficul curent (utilizati fisierul *acuratete\_l2.txt*).



Functii numpy:

```
np.sort(x) # sorteaza array-ul
np.argsort(x) # returneaza indecsi care sorteaza array-ul
np.bincount(x) # calculeaza numarul de aparitii al fiecarei valori din array
print(np.bincount(numpy.array([0, 1, 1, 3, 2, 1, 7]))) # array([1, 3, 1, 1, 0, 0, 0, 1])
np.where(x == 3) # returneaza indecsi care satisfac conditia
np.intersect1d(x, y) # returneaza intersectia celor 2 array
np.savetxt('fisier.txt', y) # salveaza array-ul y in fisierul fisier.txt
```