Perceptronul şi reţele de perceptroni în Scikit-learn

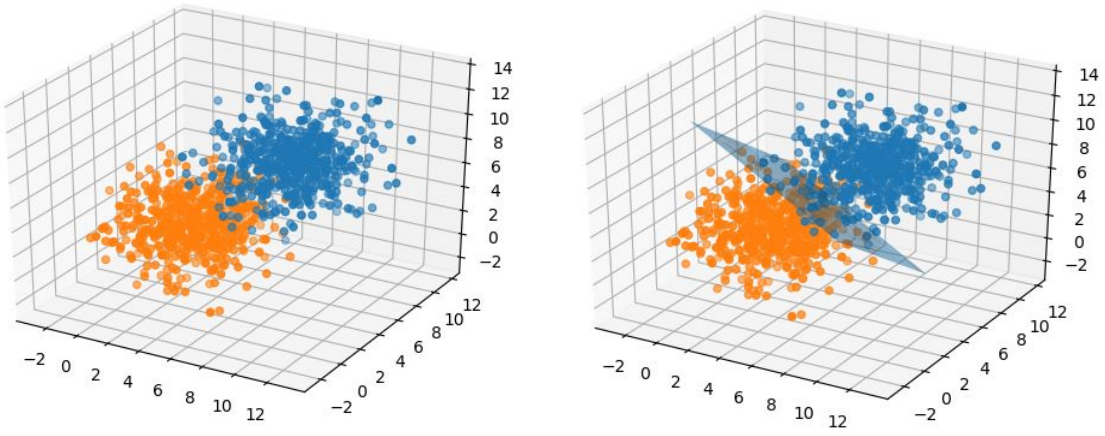

Stanga:multimea de antrenare a punctelor 3d; *Dreapta*: multimea de testare a punctelor 3d si planul de separare.

In acest laborator vom antrena un perceptron cu ajutorul bibliotecii **Scikit-learn** pentru clasificarea unor date 3d, si o retea neuronala pentru clasificarea textelor dupa polaritate. Baza de date pe care o vom folosi, pentru clasificare textelor, este **Movie Review Data**. Datele de intrare pentru reteaua pe care o vom antrena sunt reprezentarile BOW (bag-of-words) ale documentelor.

Multimile de antrenare si testare si script-ul care returneaza reprezentarea BOW se gasesc **aici**. Setul de date 3d, contine 1,000 de puncte 3d pentru antrenare, impartite in 2 clase (1- pozitiv, -1 negativ) si 400 de puncte 3d pentru testare.

Movie Review Data Set[1]

În cadrul laboratorului vom folosi setul de date “Movie Review”, care conţine recenzii de filme, împărţite în două clase: pozitive şi negative.

În folderul “*txt_sentoken*” se regăsesc 2.000 de fişiere, 1.000 conţinând recenzii pozitive şi 1000 conţinând recenzii negative. 50% din aceste date vor fi folosite pentru antrenare şi 50% pentru testare.

1. Definirea unui perceptron in Scikit-learn.

```
from sklearn.linear_model import Perceptron # importul clasei
perceptron_model = Perceptron(penalty=None, alpha=0.0001, fit_intercept=True,
max_iter=None, tol=None, shuffle=True, eta0=1.0, early_stopping=False,
```

[1] http://www.cs.cornell.edu/people/pabo/movie-review-data/

```
validation_fraction=0.1, n_iter_no_change=5)
# toti parametrii sunt optionali avand valori setate implicit
```

Parametri:

- penalty (**None, ‘l2’ sau ‘l1’ sau ‘elasticnet’, default=None**): metoda de regularizare folosita
- alpha (**float, default=0.0001**): parametru de regularizare.
- fit_intercept (**bool, default=True**): daca vrem sa invatam si bias-ului.
- max_iter (**int, default=5**): numarul maxim de epoci pentru antrenare.
- tol (**float, default=1e-3**):
  - Daca eroarea sau scorul nu se imbunatatesc timp *n_iter_no_change* epoci consecutive cu cel putin *tol*, antrenarea se opreste.
- shuffle (**bool, default=True**): amesteca datele la fiecare epoca.
- eta0 (**double, default=1**): rata de invatare.
- early_stopping (**bool, default=False**):
  - Daca este setat cu *True* atunci antrenarea se va termina daca eroarea pe multimea de validare (care va fi setata automat) nu se imbunatateste timp *n_iter_no_change* epoci consecutive cu cel putin *tol*.
- validation_fraction **: (float, optional, default=0.1)**
  - Procentul din multimea de antrenare care va fi folosit pentru validare (doar cand *early_stopping=True*). Trebuie sa fie intre 0 si 1.
- n_iter_no_change **(int, optional, default=5,** *sklearn-versiune-0.20***):**
  - Numarul maxim de epoci fara imbunatatiri (eroare sau scor).

Functiile si atributele modelului:

- **perceptron_model.fit(X, y)**: antreneaza clasificatorul utilizand stochastic gradient descent (algoritmul de coborare pe gradient), folosind parametrii setati la definirea modelului
  - X - datele de antrenare, y - etichetele
  - X are dimensiunea (num_samples, num_features)
  - y are dimensiunea (num_features,)
  - returneaza modelul antrenat.
- **perceptron_model.score(X, y)**: returneaza acuratetea clasificatorului pe multimea de testare si etichetele primite ca argumente
- **perceptron_model.predict(X)**: returneaza etichetele prezise de model
- **perceptron_model.coef_** : ponderile invatate
- **perceptron_model.intercept_** : bias-ul
- **perceptron_model.n_iter_**: numarul de epoci parcurse pana la convergenta

2. Definirea unei retele de perceptroni in Scikit-learn.

```
from sklearn.neural_network import MLPClassifier # importul clasei

mlp_classifier_model = MLPClassifier(hidden_layer_sizes=(100, ),
activation='relu', solver='adam', alpha=0.0001, batch_size='auto',
learning_rate='constant', learning_rate_init=0.001, power_t=0.5,
max_iter=200, shuffle=True, random_state=None, tol=0.0001,
momentum=0.9, early_stopping=False, validation_fraction=0.1,
n_iter_no_change=10)
```

Parametrii:

- hidden_layer_sizes (***tuple, lungime= n_layers - 2, default=(100,)***): al *i-lea* element reprezinta numarul de neurori din a*l i-lea* strat ascuns.
- activation({**'identity', 'logistic', 'tanh', 'relu'**}, **default='relu')**
  - 'Identity': $f(x) = x$
  - 'logistic' : $f(x) = \frac{1}{1+\varepsilon^{-x}}$
  - 'tanh' : $f(x) = tanh(x)$
  - 'relu' : $f(x) = max(0, x)$
- solver (**{'lbfgs', 'sgd', 'adam'}, default='adam')**: regula de invatare (update)
  - 'sgd' - stochastic gradient descent (doar pe acesta il vom folosi).
- batch_size: (***int, default='auto'***)
  - auto - marimea batch-ului pentru antrenare este *min(200, n_samples)*.
- learning_rate_init (**double, default=0.001**): rata de invatare
- max_iter (**int, default=200**): numarul maxim de epoci pentru antrenare.
- shuffle (**bool, default=True**): amesteca datele la fiecare epoca
- tol (**float, default=1e-4**) :
  - Daca eroarea sau scorul nu se imbunatatesc timp *n_iter_no_chage* epoci consecutive (*si learning_rate != 'adaptive'*) cu cel putin *tol*, antrenarea se opreste.
- n_iter_no_change **: (int, optional, default 10,** *sklearn-versiune-0.20***)**
  - Numarul maxim de epoci fara imbunatatiri (eroare sau scor).
- alpha **(float, default=0.0001)**: parametru pentru regularizare L2.
- learning_rate ({**'constant', 'invscaling', 'adaptive'**}, **default='constant'**):
  - **'constant'** : rata de invatare este constanta si este data de parametrul *learning_rate_init*.
  - **'invscaling'**: rata de invatare va fi scazuta la fiecare pas *t*, dupa formula: new_learning_rate = learning_rate_init / pow(t, power_t)
  - **'adaptive'**: pastreaza rata de invatare constanta cat timp eroarea scade. Daca eroarea nu scade cu cel putin *tol* (fata de epoca anterior) sau daca scorul pe multimea de validare (*doar daca*

ealy_stopping=True) nu creste cu cel putin *tol* (fata de epoca anteriora), rata de invatare curenta se imparte la 5.

- power_t (**double, default=0.5**): parametrul pentru learning_rate='invscaling'.
- momentum **(float, default=0.9):** - valoarea pentru momentum cand se foloseste gradient descent cu momentum. Trebuie sa fie intre 0 si 1.
- early_stopping (**bool, default=False**):
    - Daca este setat cu *True* atunci antrenarea se va termina daca eroarea pe multimea de validare nu se imbunatateste timp *n_iter_no_chage* epoci consecutive cu cel putin *tol*.
- validation_fraction **(float, optional, default=0.1)**:
    - Procentul din multimea de antrenare care sa fie folosit pentru validare (doar cand *early_stopping=True*). Trebuie sa fie intre 0 si 1.

Atribute:

- **classes_** : array sau o lista de array de dimensiune (n_classes,)
    - Clasele pentru care a fost antrenat clasificatorul.
- **loss_** : float, eroarea actuala
- **coefs_** : lista, lungimea = n_layers - 1
    - Al ***i***-lea element din lista reprezinta matricea de ponderi dintre stratul ***i*** si ***i + 1***.
- **intercepts_ :** lista, lungimea n_layers - 1
    - Al ***i***-lea element din lista reprezinta vectorul de bias corespunzator stratului ***i + 1***.
- **n_iter_** : int, numarul de epoci parcurse pana la convergenta.
- **n_layers_** : int, numarul de straturi.
- **n_outputs_** : int, numarul de neuroni de pe stratul de iesire.
- **out_activation_** : string, numele functiei de activare de pe stratul de iesire.

Functii:

- **mlp_classifier_model.fit(X, y)**:
    - Antreneaza modelul pe datele de antrenare X si etichetele y cu parametrii setati la declarare.
    - X este o matrice de dimensiune (n_samples, n_features).
    - y este un vector sau o matrice de dimensiune (n_samples,) - pentru clasificare binara si regresie, (n_samples, n_outputs) pentru clasificare multiclass.
    - Returneaza modelul antrenat.
- **mlp_classifier_model.predict(X):**
    - Prezice etichetele pentru X folosind ponderile invatate.
    - X este o matrice de dimensiune (n_samples, n_features).
    - Returneaza clasele prezise intr-o matrice de dimensiune (n_samples,)- pentru clasificare binara si regresie, (n_samples, n_outputs) pentru clasificare multiclass.
- **mlp_classifier_model.predict_proba(X):**

- Prezice probabilitatea pentru fiecare clasa.
- X este o matrice de dimensiune (n_samples, n_features).
- Returneaza o matrice de (n_samples, n_classes) avand pentru fiecare exemplu si pentru fiecare clasa probabilitatea ca exemplul sa se afle in clasa respectiva.

- **mlp_classifier_model.score(X, y):**
  - Returneaza acurateta medie in functie de X si y.
  - X este o matrice de dimensiune (n_samples, n_features).
  - y are dimeniunea (n_samples,) - pentru clasificare binara si regresie, (n_samples, n_outputs) pentru clasificare multiclass.

Exerciţii

1. Antrenati un perceptron pe multimea de puncte 3d, pana cand eroare nu se imbunatateste cu 1e-5 fata de epocile anterioare, cu rata de invatare 0.1. Calculati acuratetea pe multimea de antrenare si testare, apoi afisati ponderile, bias-ul si numarul de epoci parcuse pana la convergenta. Plotati planul de decizie al clasificatorului cu ajutorului functiei *plot3d_data_and_decision_function*.

```
from mpl_toolkits import mplot3d
import numpy as np
import matplotlib.pyplot as plt
def plot3d_data_and_decision_function(X, y, W, b):
    ax = plt.axes(projection='3d')
    # create x,y
    xx, yy = np.meshgrid(range(10), range(10))
    # calculate corresponding z
    # [x, y, z] * [W[0], W[1], W[2]] + b = 0
    zz = (-W[0] * xx - W[1] * yy - b) / W[2]
    ax.plot_surface(xx, yy, zz, alpha=0.5)
    ax.scatter3D(X[y == -1, 0], X[y == -1, 1], X[y == -1, 2], 'b');
    ax.scatter3D(X[y == 1, 0], X[y == 1, 1], X[y == 1, 2], 'r');
    plt.show()
```

2. Antrenati o retea de perceptroni care sa clasifice textele dupa polaritate (setul de date Movie Review Data) folosind ca date de intrare reprezentarea BOW a documentelor. Datele trebuie normalizate prin scaderea mediei si impartirea la deviatia standard. Reteaua trebuie sa foloseasca **algoritmul de coborare pe gradient**, sa aiba **2 straturi ascunse** cu cate **[30, 20]** perceptroni pe fiecare strat, **functia de activare ‘tanh’**, **rata de invatare 0.01** si **‘dezactivati’ momentum** (setati valoarea lui cu 0). Calculati acuratetea pe multimea de antrenare si de testare, apoi afisati numarul de epoci efectuate.

a. La reteaua anterioara adaugati ‘**early stopping**’ cu procentul de validare implicit, apoi reantrenati reteaua. Ce observati?
b. La reteaua de la *exercitiul 2* adaugati **learning_rate=’adaptive’**, apoi reantrenati. Cum influenteaza acuratetea?
c. La reteaua anterioara adaugati **momentum** cu valoarea 0.9, apoi reantrenati. Cum influenteaza acuratetea?
d. La reteaua anterioara setati parametrul de **regularizare *alpha* cu 0.5**, apoi reantrenati. Cum influenteaza acuratetea?
e. La reteaua anterioara adaugati ‘**early stopping**’, vedeti cate epoci are nevoie reteaua pentru a converge, apoi reantrenati reteaua cu acelasi numar de epoci, dar fara *early stopping*. Cum influenteaza acuratetea?